iPhone で動く日本語意味検索：Core ML 版 ruri-v3 と Apple NLContextualEmbedding の比較

中津川昌弘 (Masahiro Nakatsugawa)

2026-10-11

目次

要旨 (Abstract) . . . 2
1. 検証方法 . . . 2
1.1 使用モデル . . . 2
1.2 評価データセット . . . 3
1.3 実行環境 . . . 3
2. 結果 . . . 3
2.1 日本語セット: ruri-v3-130m vs Apple(日本語モデル) . . . 3
2.2 英語セット: Apple(英語モデル) の参考値 . . . 4
2.3 「月」の文字を含まない間接表現 . . . 4
2.4 推論速度 (ruri-v3-130m) . . . 5
2.5 モデルサイズの影響: ruri-v3-130m vs ruri-v3-310m . . . 5
3. 考察: なぜ ruri-v3 は古典日本語を捉えられ、Apple は捉えられないのか . . . 6
3.1 トークナイザと学習データのドメイン差 (仮説) . . . 6
3.2 スコア分布の形状から見えること . . . 6
3.3 プレフィックススキームの寄与 . . . 6
4. Apple NLContextualEmbedding の強みと弱み . . . 6
4.1 強み . . . 6
4.2 弱み . . . 6
5. 結論と今後の課題 . . . 7
5.1 実務上の推奨 . . . 7
5.2 本研究の限界 . . . 7
5.3 今後の課題 . . . 7
付録 A: 使用クエリ全文 . . . 8
付録 B: 使用文書全文 (§2.1・2.3・2.5 で使用したもの) . . . 8
参考文献 . . . 9

プレプリント（未査読）。ソース・モデル・評価コード・デモアプリは *https://github.com/masahiroid/ruri-coreml* にて公開。

要旨 (Abstract)

本稿は、日本語文埋め込みモデル ruri-v3(cl-nagoya/ruri-v3-130m) を Core ML に変換して iPhone 実機上で動作させたものと、iOS/macOS に標準搭載されている Apple の文脈埋め込み機能 `NLContextualEmbedding`(Natural Language framework) を、日本語 (現代文・古典文語) および英語の意味的類似度検索タスクで比較検証した結果をまとめる。

結論: 日本語、特に古典文語を含む意味検索タスクにおいて、ruri-v3 は Apple 標準搭載モデルに対し明確な優位性を示した。Apple 側の日本語モデルは、徒然草・祇園精舎・芭蕉の句などの古典文学作品を、話題の異なる無関係な現代文 (飲食店レビュー、天気予報) よりも低い類似度スコアに位置づけており、古典日本語の意味理解において実用に耐えない挙動を示した。一方 ruri-v3 は、古典 4 文書すべてを無関係文書より上位に置き、対象語 (「月」) を一切含まない間接的表現や、言語をまたいだクエリ (日本語クエリに対する英語文書) に対しても意味的に妥当なランキングを維持した。

Apple 側の強みは、追加のモデルバンドルや実装コストなしに OS 標準機能として利用できる点、および英語における高い分離性能である。用途に応じた使い分けの指針は §5.1 にまとめる。

本研究は *iPhone* 実機 *(iPhone 17 Pro / iOS 27)* 上で実施した。*Core ML* 変換した *ruri-v3* は、*fp16* 版 *(265MB)*・*int8* 量子化版 *(133MB)* ともに *GPU/Neural Engine* 上で動作し、定常状態で *1* 文あたり約 *5ms* と、*Apple* 標準モデル *(*約 *9*〜*10ms)* より高速であった。*int8* 量子化によるスコア変化は最大 *0.0042* で、検索順位への影響はほぼなかった。使用した評価データセットは付録に全文を記録する。

1. 検証方法

1.1 使用モデル

モデル	実体	実行環境	備考
ruri-v3-130m	cl-nagoya/ruri-v3-130m(ModernBERT-Ja ベース、132M パラメータ、隠れ層 512 次元)	Core ML(fp16、およびその int8 重み量子化版)	自作の PyTorch→Core ML 変換パイプラインを使用 (masahiroid/ruri-coreml)
Apple(日本語)	`NLContextualEmbedding(language: .japanese)`	iOS 27 標準搭載 (Natural Language framework)	CJK スクリプトモデル、512 次元
Apple(英語)	`NLContextualEmbedding(language: .english)`	同上	Latin スクリプトモデル

ruri-v3 は入力テキストの先頭に役割を示す文字列 (検索クエリ: / 検索文書:) を付与する「1+3 プレフィックススキーム」を採用しており、本研究でもこの仕様に従った。Apple 側にはプレフィックスの概念はない。

両モデルとも Transformer ベースの文脈型埋め込み (contextual embedding) であり、トークン単位のベクトルを平均プーリングして L2 正規化した文埋め込みを得る点で手法上の共通性がある (ruri-v3 は export 時にグラフ内で実施、Apple 側はアプリ側で実施)。ただし両者のベクトル空間は完全に異なるので、スコアの絶対値を直接比較することはできず、**各モデル内での相対順位と分離度**を比較の軸とした。

1.2 評価データセット

クエリは日英両語で統一:「月を見て懐かしい気持ちになる話」/「A story about feeling nostalgic while looking at the moon」。候補文書 19 件 (日本語 15 件・英語 4 件) を以下のカテゴリで構成した (全文は付録 B)。

1. **直接一致・月見の思い出・望郷** (現代文・英語、「月」を明示) —意味的に最も強く一致するもの。
2. **古典・雅語** (芭蕉の句、百人一首、徒然草、竹取物語) —文語で「月」と「想い出」に触れるもの。
3. **間接表現** (「十五夜」「満ち欠け」「望の夜」「玉兎」など、「月」の文字を一切使わずに月を暗示) —表面的な単語一致ではなく、意味理解を別途測るための統制条件。
4. **近い誤答** (太陽の話) —「天体を見上げる」という状況は類似しているが「懐かしさ」の要素がない、区別能力を見るディストラクタ。
5. **完全に無関係** (祇園精舎の無常観、味噌ラーメン、天気予報、決算報告の英文) —ベースライン (「床」) の測定。§2.5 の参考検証のみランダム文字列も加えた。

Apple 側は言語ごとに別モデルのため、日本語モデルは日本語文書のみ、英語モデルは英語文書のみを対象とした。ruri-v3 は全文書を単一モデルで処理した。

1.3 実行環境

意味的類似度の比較は iPhone 17 Pro 実機上で実施 (Xcode ビルド、iOS 27)。推論速度の実測値も同実機上でアプリのログ出力を介して取得した (詳細は §2.4)。

検証に使った iOS アプリ **RuriDemo** は GitHub で公開している。Hugging Face からモデルをダウンロードしてビルドすれば、本レポートと同じクエリ・文書で同じ実験を実機で再現できる (類似度スコアと推論時間は Xcode のコンソールに出力される)。手順は RuriDemo/MANUAL.md を参照。

2. 結果

2.1 日本語セット: ruri-v3-130m vs Apple(日本語モデル)

同一のクエリ・同一の候補文書集合に対し、iPhone 17 Pro 実機で得られたスコア (内積、値が大きいほど類似) をモデル別に並べる。ruri-v3 は fp16 版と int8 量子化版の両方を示す。

文書	ruri-v3 fp16	ruri-v3 int8	Apple(日本語)
現代文・直接一致	**0.9256**	**0.9247**	**0.8063**
現代文・月見の思い出	**0.9205**	**0.9209**	0.7990
現代文・望郷	0.8884	0.8890	**0.8084**(1 位)
古典・百人一首 (紫式部)	0.8582	0.8581	0.5590
古典・竹取物語 (かぐや姫)	0.8545	0.8554	0.5010
古典・徒然草	0.8461	0.8462	0.5340
古典・芭蕉 (名月の句)	0.8202	0.8214	0.5100
祇園精舎 (無関係・古語)	0.7916	0.7916	0.5111
味噌ラーメン (無関係)	0.7403	0.7398	0.5588
今日の天気 (無関係)	0.7365	0.7370	0.6027
近い誤答・太陽 (懐かしさなし)	0.8243	0.8251	0.7049
英語・直接一致	0.8912	0.8908	—
英語・詩的表現	0.8809	0.8805	—
英語・望郷	0.8721	0.8722	—

文書	ruri-v3 fp16	ruri-v3 int8	Apple(日本語)
英語・無関係 (決算報告)	0.7468	0.7461	—

(—: Apple の日本語モデルは英語文書を対象にできない。§2.2 参照)

量子化の影響: fp16 版と int8 版のスコア差は全 19 文書で最大 0.0042(古典風・玉兎)、それ以外は 0.0012 以下であり、順位の変動は僅差 (0.0008) の 6 位・7 位の入れ替わり 1 件のみであった。int8 量子化による実用上の精度劣化は認められない。

最重要の観察点: ruri-v3 では古典 4 文書 (0.82〜0.86) が無関係文書 (0.74〜0.79) を常に上回るのに対し、Apple(日本語) では古典 4 文書 (0.50〜0.56) が**無関係な現代文 (味噌ラーメン 0.5588、天気 0.6027) を一貫して下回った**。Apple モデルにとって、徒然草や芭蕉の句は「味噌ラーメンのレビュー」より類似度の低いノイズとして扱われている。

言語横断: ruri-v3 は日本語クエリに対し、英語の関連 3 文書 (0.87〜0.89) を英語の無関係文書 (0.75) より明確に上位に置いた。単一モデルで日英を横断した検索が成立している。

近い誤答への反応:「太陽を見上げる」ディストラクタ (懐かしさの要素なし) に対しては、ruri-v3 も 0.8243 と比較的高いスコアを与え、古典・芭蕉 (0.8202) をわずかに上回った。Apple 日本語モデルも同文書を 4 位 (0.7049) とし、古典全文書より上位に置いた。「天体を見上げる」という状況の類似に両モデルとも引きずられており、情緒 (懐かしさ) の区別は両者に共通する課題である。

2.2 英語セット: Apple(英語モデル) の参考値

Apple は言語ごとに別モデルなので、英語文書は英語モデルでのみ検索可能。参考までに実機実測値を記す (ruri-v3 の対応スコアは §2.1 参照)。

文書	Apple(英語)
英語・詩的表現	**0.9237**
英語・直接一致	0.9188
英語・望郷	0.9047
英語・無関係 (決算報告)	0.7604

Apple の英語モデルは、日本語モデルと対照的に良好な分離 (一致で 0.90 以上、無関係で 0.76) を示した。これは Apple のモデル品質一般の問題ではなく、**日本語 (特に古典文語) に固有の弱さ**であることを裏付ける。

2.3 「月」の文字を含まない間接表現

キーワード一致ではなく意味を捉えているかを別途検証した。

文書 (「月」の字なし)	ruri-v3 fp16	ruri-v3 int8	Apple(日本語)
現代・満ち欠けの描写	0.8716	0.8730	0.6934
現代・十五夜・すすき	0.8517	0.8515	0.7045
古典風・望の夜	0.8359	0.8364	0.6113
古典風・玉兎 (月の雅称)	0.8305	0.8263	0.5799

ruri-v3 では 4 文書とも無関係文書のフロア (0.74〜0.79) を明確に上回り、表面的な文字列一致ではなく文脈意味を捕捉していることが確認できた。Apple 日本語モデルは現代文の 2 件 (0.69〜0.70) を無関係文書 (0.56〜0.60) より上位に置いたが、古典風の 2 件は玉兎 (0.5799) が天気予報 (0.6027) を下回るなど、§2.1 と同じく文語体で分離が崩れた。

2.4 推論速度 (ruri-v3-130m)

iPhone 17 Pro 実機 (iOS 27) で、アプリのログから計測した。Core ML の実行先は既定 (`MLComputeUnits.all`: CPU/GPU/Neural Engine を自動選択)。

指標	ruri-v3 fp16	ruri-v3 int8 量子化	Apple 日本語	Apple 英語
モデルサイズ	265MB	133MB	0(OS 内蔵)	0(OS 内蔵)
初回呼び出し (コンパイル/ウォームアップ含む)	417ms	2,069ms	57ms	55ms
定常状態 (2 回目以降の平均、トークナイズ込み)	**約 5.4ms**	**約 4.7ms**	約 9.6ms	約 9.2ms

ruri-v3 は定常状態で Apple 標準モデルの約 2 倍高速であった。int8 量子化版はサイズが fp16 版の半分でありながら速度は同等以上で、モバイル配布に最も適した構成である。初回呼び出しのみ Neural Engine 向けの準備処理で時間がかかる (int8 版で約 2 秒。一度準備されたモデルは再ロード時に短縮され、fp16 版の 2 回目のロードでは 33ms だった) が、アプリ起動時に 1 回ダミー推論を行っておけば実用上の影響はない。**速度・サイズの両面で ruri-v3 の採用を妨げる要因はなく、§2〜3 で示した意味理解の精度差 (特に古典日本語) がそのまま選択の決め手となる。**

2.5 モデルサイズの影響: ruri-v3-130m vs ruri-v3-310m

※ この節のみ、1.3 の実機検証とは異なり、**Mac 上で Python/coremltools を使い fp16 モデルで比較**した参考データである (iPhone 実機での 310m 検証は未実施、§5.3 の今後の課題参照)。

文書	130m	310m	差分
現代文・直接一致	0.9251	0.9407	+0.0156
現代文・月見の思い出	0.9204	0.9321	+0.0117
現代文・望郷	0.8882	0.9078	+0.0196
英語・直接一致	0.8913	0.8844	−0.0069
英語・詩的表現	0.8810	0.8765	−0.0045
英語・望郷	0.8719	0.8721	+0.0002
古典・百人一首	**0.8584**	**0.8276**	−0.0308
古典・竹取物語	0.8545	0.8477	−0.0068
古典・徒然草	**0.8459**	**0.8215**	−0.0244
古典・芭蕉	0.8200	0.8148	−0.0052
祇園精舎 (無関係)	0.7885	0.7798	−0.0087
英語・無関係	0.7470	0.7455	−0.0015
ランダム文字列	0.7434	0.7361	−0.0073
味噌ラーメン (無関係)	**0.7407**	**0.7731**	**+0.0324**

ノン自明な発見: 現代文の真の一致は 310m で一貫してスコアが上昇した一方 (最大 +0.02)、**古典文学を 4 件全てでスコアが低下し (最大 −0.031、百人一首)**、同時に無関係な味噌ラーメンのスコアは上昇した (+0.032)。つまり**モデルを大きくすれば古典理解が向上するわけではなく、むしろ古典文と無関係文の分離度はわずかに縮小した**。これは、モデルサイズの拡大が主に現代日本語・英語の表現力向上に寄与しており、古典日本語理解は別の要因 (学習データに含まれる古典テキストの割合など) により強く依存する可能性を示唆する。単純に「大きいモデルを使えば良い」とは言えない点は、実務上のモデル選択 (§5.1) にも影響する。

3. 考察: なぜ ruri-v3 は古典日本語を捉えられ、Apple は捉えられないのか

3.1 トークナイザと学習データのドメイン差 (仮説)

ruri-v3 は ModernBERT-Ja を基盤とし、専用の Unigram(SentencePiece) トークナイザ (語彙 10 万超) を持つ。開発元の cl-nagoya は学術論文 (arXiv:2409.07737) で学習手法とデータ構成を公開している。一方、Apple の `NLContextualEmbedding` は CJK スクリプト向けの単一モデルで日中韓の 3 言語をカバーしており、学習データやアーキテクチャの詳細は公開されていない。

この非対称性 (一方は論文で検証可能、他方はブラックボックス) により、Apple 側の不具合の原因を内部実装のレベルで確定することはできない。ただし概念上、CJK スクリプトモデルは**現代の日・中・韓テキストで共通の学習コーパスに偏りやすく**、文語文法 (係り結び、古語助動詞「けり」「たまふ」「なり」など) や旧仮名遣いを含む文章への適応は、日本語専用モデルより優先度が低くなりやすい構造的リスクがある。

3.2 スコア分布の形状から見えること

本研究で特に重要なのは、古典文書のスコアが単に低いのではなく、**無関係な現代文よりも低い**という逆転現象である。これは単に「古典に弱い」を超えて、**古典文を意味的に理解できていない (= ランダムなトークン列と大差ない埋め込みしか生成できていない)** 可能性を示唆する。対照的に、ruri-v3 ではランダム文字列のスコア (0.7434、§2.5 の Mac 参考値) と古典文のスコア (0.82〜0.86) が明確に区別されている。

3.3 プレフィックススキームの寄与

ruri-v3 は「検索クエリ」/「検索文書」という役割プレフィックスを付与して学習されており、検索タスクに特化した埋め込み空間を形成しやすい。Apple の NLContextualEmbedding にはこのようなタスク別プロンプト機構がなく、汎用的な文脈埋め込みとして設計されている。この設計思想の違いも、検索特化タスクでの差に寄与していると考えられる。

4. Apple NLContextualEmbedding の強みと弱み

4.1 強み

- **ゼロ・セットアップ:** iOS 17 以降の OS に標準搭載されており、モデルファイルのバンドルやトークナイザの自前実装が不要。アプリサイズへの影響が事実上ゼロ。
- **英語での高い分離性能:** §2.2 の通り、英語では真の一致と無関係文の差が大きく、実用性は高いと見られる。
- **プライバシー:** 全てオンデバイス完結。外部 API やデータ送信不要 (この点は ruri-v3 の Core ML 変換版も同様)。

4.2 弱み

- **日本語古典文学への実用不可:** §2.1 の通り、古典作品を無関係な現代文より低くランクさせる。古語・古典を扱う検索アプリには事実上使えない。

- **言語サイロ化:** `NLContextualEmbedding` は言語/スクリプトごとに別モデルであり、日本語クエリで英語文書を検索するといった言語横断検索が構造的に不可能。ruri-v3 は単一モデルでこれを一定程度実現した (§2.1・アブストラクト参照)。
- **不透明性:** 学習データ・手法の公開がなく、不具合の原因究明や改善の余地の検証が外部から事実上不可能。
- **使い勝手のコスト:** 本研究中にもアセットの初回ダウンロード・コンパイル待ちが発生し、初回起動のレイテンシは小さくない (本レポート作成中の実機検証では、リトライ待機を含め数十秒規模の初回レイテンシを観測)。

5. 結論と今後の課題

5.1 実務上の推奨

用途	推奨
日本語 (現代文・古典を問わない) の意味検索	**ruri-v3**
古典文学・国語教育・古文検索アプリ	**ruri-v3**(Apple 標準モデルは実用不可)
英語単一言語のテキスト類似度	Apple で十分 (追加実装コストを避けたい場合)
日英横断検索 (1 つのクエリで多言語文書を検索)	**ruri-v3**(Apple は構造的に不可)
アプリサイズを極小化したい	Apple(ゼロバイト) ※ 精度を犠牲にする

配布する ruri-v3 の Core ML モデルは、**fp16 版とその int8 量子化版**の 2 種で十分である。

モデル	fp16	int8 量子化
ruri-v3-130m	265MB	**133MB**(モバイル推奨)
ruri-v3-310m	630MB	316MB

公開先: masahiroid/ruri-v3-130m-coreml、masahiroid/ruri-v3-310m-coreml

5.2 本研究の限界

- テスト文書 19 件・クエリ 1 種類と規模が小さく、定量的な統計検定 (有意差検定など) は行っていない。あくまで事例検証である。
- 実機検証は ruri-v3-130m(系列長 128) のみ。310m は §2.5 の通り Mac 上の fp16 参考データのみで、実機での完全検証は未実施。
- 本研究時点の iOS 27 はベータ版であり、正式版で速度や挙動が変わる可能性がある。
- クエリ 1 種類のため、「懐かしさ」のような情緒的要素の区別 (§2.1 の近い誤答) について一般化はできない。
- Apple 側のアーキテクチャ・学習データが非公開のため、§3 の考察は仮説の域を出ない。

5.3 今後の課題

1. ruri-v3-310m で実機上での完全な検証を行い、モデルサイズと古典理解能力の関係を確認する (§2.5 の参考データを実機・全文書セットで再現)。
2. テスト文書数を拡張し (実際の古典文学コーパスなど)、定量的な検定を行う。
3. 本レポートの変換パイプラインと iOS デモアプリは、cl-nagoya/ruri-v3 のエコシステムへの貢献として公開を予定している。

付録 A: 使用クエリ全文

言語	クエリ全文
日本語	月を見て懐かしい気持ちになる話
英語	A story about feeling nostalgic while looking at the moon

付録 B: 使用文書全文 (§2.1・2.3・2.5 で使用したもの)

† は §2.5(130m vs 310m のモデルサイズ比較、Mac 上 fp16 での参考検証) でのみ使用し、§2.1(実機・全 19 件セット) には含まれない文書。

No.	ラベル	言語	全文
1	現代文・直接一致	ja	夜空に浮かぶ月を眺めていたら、昔のことが思い出されて胸が熱くなった。
2	現代文・月見の思い出	ja	満月を見ていると、子供の頃に家族で月見をした夜を思い出す。
3	現代文・望郷	ja	窓から見える月がとても綺麗で、なぜか故郷を思い出して懐かしくなった。
4	古典・芭蕉 (名月の句)	ja	名月や池をめぐりて夜もすがら
5	古典・百人一首 (紫式部)	ja	めぐり逢ひて見しやそれとも分かぬ間に雲隠れにし夜半の月かな
6	古典・徒然草	ja	花はさかりに、月はくまなきをのみ見るものかは。
7	古典・竹取物語 (かぐや姫)	ja	かぐや姫、月の顔見るは、忌むこととて制しけれども、ともすれば人間にも月をあはれがりたまふ。
8	祇園精舎 (無関係・古語)	ja	祇園精舎の鐘の声、諸行無常の響きあり。娑羅双樹の花の色、盛者必衰の理をあらはす。
9	味噌ラーメン (無関係)	ja	この味噌ラーメンは煮干しだしが効いていて、とても美味しかった。
10	今日の天気 (無関係)	ja	今日の東京の天気は晴れ、最高気温は 26 度の見込みです。

No.	ラベル	言語	全文
11	現代・間接 (満ち欠け、月の字なし)	ja	満ち欠けを繰り返しながら夜空を渡っていくあの白い光を、幼い頃はよく縁側から眺めたものだ。
12	現代・間接 (十五夜、月の字なし)	ja	十五夜の夜、すすきを飾って夜空に浮かぶ丸い光を眺めるのが、祖母の家での毎年の習わしだった。
13	古典風・間接 (望の夜、月の字なし)	ja	望の夜、庭に出でて空を仰げば、昔のことのみ思ひ出でられける。
14	古典風・間接 (玉兎、月の字なし)	ja	玉兎西へ傾く頃、庭に佇みて往時を偲びけり。
15	近い誤答・太陽 (懐かしさなし)	ja	朝、太陽が昇るのを見て、今日も一日頑張ろうと思った。
16	英語・直接一致	en	Looking at the full moon tonight brought back memories of my childhood home.
17	英語・望郷	en	Every time I see the moon rise, I feel a quiet longing for the town where I grew up.
18	英語・詩的表現	en	The old moon always makes me think of summers long gone.
19	英語・無関係	en	The quarterly earnings report showed a 12% increase in revenue.
20†	ランダム文字列 (無関係)	—	xqz 42 %%% asdlkj —- 9284

文書 1〜19 は RuriDemo の `RuriDemo/SampleData/MoonNostalgiaDataset.swift` に Swift の構造体として定義されており、実機アプリで再実行して結果を再現できる。

古典文書 (4〜7、13〜14) の出典: 松尾芭蕉の句 (4)、『百人一首』第五十七番・紫式部 (5)、『徒然草』第百三十七段冒頭 (6、口語訳ではなく原文の抜粋)、『竹取物語』かぐや姫の場面の要約的言い換え (7、原文の逐語引用ではない)、13・14 は本研究のために著者が古文体を模して作成した創作文 (原典からの引用ではない)。

参考文献

1. Tsukagoshi, H., & Sasano, R. (2024). *Ruri: Japanese General Text Embeddings*. arXiv:2409.07737. https://arxiv.org/abs/2409.07737

2. cl-nagoya. *ruri-v3-130m / ruri-v3-310m.* Hugging Face. https://huggingface.co/cl-nagoya/ruri-v3-130m
3. SB Intuitions. *JMTEB: Japanese Massive Text Embedding Benchmark.* Hugging Face Datasets. https://huggingface.co/datasets/sbintuitions/JMTEB
4. Apple. *Natural Language —NLContextualEmbedding.* Apple Developer Documentation. https://developer.apple.com/documentation/naturallanguage/nlcontextualembedding
5. Apple. *Core ML Tools (coremltools) Documentation.* https://apple.github.io/coremltools/
6. Nakatsugawa, M. (2026). *ruri-coreml: ruri-v3 Core ML conversion, iOS demo, and verification.* GitHub. https://github.com/masahiroid/ruri-coreml